

Lucas da Mata Guimarães

**Sistema Flexível para Treino e Avaliação de
Modelos de Regressão (GAM, GLM e MARS)
com Conjuntos de Dados Arbitrários.**

São Paulo - Brasil

2025

Lucas da Mata Guimarães

Sistema Flexível para Treino e Avaliação de Modelos de Regressão (GAM, GLM e MARS) com Conjuntos de Dados Arbitrários.

Monografia apresentada na disciplina Trabalho de Conclusão de Curso, como parte dos requisitos para obtenção do título de Bacharel em Ciência da Computação.

Centro Universitário Senac - Santo Amaro
Bacharelado em Ciência da Computação

Orientador: Afonso Cesar Lelis Brandão

São Paulo - Brasil
2025

Agradecimentos

Agradeço à minha família pela criação carinhosa e com princípios que me foi dada, bem como por todo o apoio incondicional recebido neste caminho que decidi trilhar.

Ao Professor Orientador Afonso Cesar Lelis Brandão e ao Professor Mario Leandro Pires Toledo pelo inestimável apoio e orientação inicial para o projeto.

Aos professores do Senac no curso de Ciência da Computação, por proporcionarem um aprendizado de alta qualidade e por servirem de amigos em cada uma das etapas da nossa formação.

Resumo

Modelos preditivos são ferramentas essenciais em diversas áreas, como finanças e biologia, fornecendo suporte quantitativo para a tomada de decisões. Um exemplo prático é a avaliação do impacto do crescimento urbano na população de espécies de uma determinada região.

Este trabalho propõe a criação de um processo semiautomático para facilitar a construção e avaliação de modelos preditivos, projetado para operar com conjuntos de dados arbitrários.

Para validar o sistema, foram utilizados dois conjuntos de dados distintos: um com dados contínuos e outro com dados categóricos. O sistema foi responsável por particionar os dados para treino e teste, aplicar os pré-processamentos necessários para a modelagem e selecionar as métricas de avaliação mais adequadas para cada caso.

O sistema demonstrou ser capaz de identificar corretamente o tipo de dado (contínuo ou categórico), adaptando o pré-processamento e as métricas de avaliação de acordo. Contudo, a geração de modelos a partir de dados categóricos apresentou falhas em uma abordagem generalista.

Palavras-chave: Modelos Preditivos, GAM, GLM, MARS, Avaliação de Modelos.

Abstract

Predictive models are used in a wide variety of fields, from finance to biology, where accurate models are needed to support decision-making. For example, we can cite the impact of urban growth on the species population of a given region.

In view of this need, this work aims to create a semi-automatic process to facilitate the creation and evaluation of predictive models for future use, capable of working with arbitrary datasets.

For the validation of the proposed system, two datasets were used, representing a prediction with continuous data and with categorical data. The system was responsible for separating the data for testing and training, performing the necessary treatments to make the model's construction viable, and identifying the most suitable metrics for its evaluation.

Although the proposed system proved capable of correctly identifying the data type, and consequently how to prepare it and which evaluation tests to use, the creation process for models working with categorical data was flawed when applied to a generalist scope.

Key-words: Predictive Models, GAM, GLM, MARS, Model Evaluation.

Lista de ilustrações

Figura 1 – Regressão Linear Simples	15
Figura 2 – Regressão Linear Múltipla	17
Figura 3 – Curva Spline	23
Figura 4 – Arquitetura do sistema	27
Figura 5 – Diagrama de Sequência - MODELO	28

Lista de tabelas

Tabela 1 – Matriz de Confusão	18
Tabela 2 – Métricas de um modelo contínuo	35

Lista de abreviaturas e siglas

GAM	Generalized Additive Models
GLM	Generalized Linear Model
MARS	Multivariate Adaptive Regression Spline
ML	Maximum likelihood
SDM	Modelo de Distribuição de espécie

Sumário

1	INTRODUÇÃO	10
1.1	Contexto	10
1.2	Justificativa	10
1.3	Objetivo Geral	11
1.3.1	Objetivos Específicos	11
2	REVISÃO BIBLIOGRÁFICA	13
2.1	Modelos Computacionais	13
2.1.1	Modelos Lineares	13
2.1.2	Métodos de avaliação de Modelos Computacionais	17
2.1.2.1	MAE e RMSE	17
2.1.2.2	Matriz de Confusão	18
2.1.2.3	Acurácia	19
2.1.3	Modelos de Distribuição de Espécies	19
2.1.3.1	GLM - Generalized Linear Model	20
2.1.3.2	GAM - Generalized Additive Model	21
2.1.3.3	MARS - Multivariate Adaptive Regression Spline	22
2.2	Linguagem R	24
2.2.1	Packages	25
2.3	Trabalhos relacionados	25
3	DESENVOLVIMENTO	27
3.1	Arquitetura	27
3.2	Recursos tecnológicos	28
3.3	Dados	29
3.3.1	Armazenamento	29
3.4	Implementação	30
3.4.1	Modelos	32
3.4.1.1	Avaliação	33
4	RESULTADOS	35
5	CONCLUSÃO	37
5.1	Trabalhos Futuros	37
	REFERÊNCIAS	39
	APÊNDICES	43
	APÊNDICE A – ARQUITETURA DO SISTEMA	44

1 Introdução

1.1 Contexto

A modelagem computacional tem impulsionado avanços significativos em diversas áreas da Biologia (COSME, 2025a). Entre suas aplicações, destacam-se os modelos de distribuição de espécies (SDMs), que permitem visualizar e prever a dinâmica de populações da fauna e da flora em uma determinada região ao longo do tempo (ELITH; LEATHWICK, 2009).

Dentre os SDMs mais proeminentes, encontram-se o *Generalized Additive Models* (GAM) (HASTIE; TIBSHIRANI, 1986) e o *Generalized Linear Model* (GLM) (PAUL; SAHA, 2007). O GLM é uma extensão dos modelos lineares tradicionais que permite modelar dados com distribuições de erro não normais. O GAM, por sua vez, é uma extensão semiparamétrica do GLM, capaz de capturar relações não lineares e não monótonas entre as variáveis (GUISAN; EDWARDS; HASTIE, 2002).

Outro modelo relevante é o *Multivariate Adaptive Regression Spline* (MARS), que combina particionamento recursivo e ajuste por *splines* para construir um modelo preditivo robusto a partir de uma análise regressiva (FRIEDMAN, 1991).

A implementação desses modelos é frequentemente realizada na linguagem de programação R, uma ferramenta consolidada na comunidade de ciência de dados, reconhecida por sua robustez em cálculos e análises estatísticas (AWARI, 2022).

Contudo, o treinamento desses modelos pode demandar um alto custo computacional, exigindo considerável poder de processamento e memória (COSME, 2025a). Essa característica, muitas vezes negligenciada em trabalhos que se concentram apenas na análise dos modelos, pode tornar o processo de treinamento lento e dependente de computadores de alto desempenho ou de serviços de computação em nuvem (RICHTER, 2025).

A necessidade de monitorar populações de espécies em ambientes urbanos ou em suas proximidades torna a eficiência do processo de modelagem um fator crítico. A agilidade na obtenção de resultados é fundamental, considerando que o ciclo completo envolve desde a coleta de dados e o treinamento do modelo até a validação e a análise final.

1.2 Justificativa

A identificação da distribuição de espécies em um determinado ambiente e intervalo de tempo é fundamental para compreender como as populações respondem a alterações ambientais, como a flutuação na abundância de outras espécies. Muitas dessas alterações são impulsionadas pela atividade humana, como a expansão da construção civil e de infraestrutura (AMETEPEY; ANSAH, 2014). Portanto, a capacidade de estimar o impacto dessas ações é crucial para a conservação da biodiversidade.

A aplicação de modelos estatísticos, como o *Generalized Additive Models* (GAM), o *Generalized Linear Model* (GLM) e o *Multivariate Adaptive Regression Spline* (MARS), permite analisar e prever esses fenômenos. Esses modelos, embora compartilhem a aborda-

gem de máxima verossimilhança (*Maximum Likelihood* - ML), diferem em sua capacidade de lidar com diferentes tipos de dados, bem como no custo computacional associado ao seu treinamento e utilização (NORBERG et al., 2019).

A eficácia dos modelos de distribuição de espécies está diretamente ligada à disponibilidade de dados de ocorrência e, em alguns casos, de ausência de espécies (WISZ et al., 2008). No entanto, a coleta de dados pode ser um desafio para espécies raras ou de habitat restrito (STOCKMAN; BEAMER; BOND, 2006). Nesse contexto, a ciência cidadã surge como uma ferramenta valiosa, permitindo a colaboração de voluntários na coleta de dados e na identificação de áreas prioritárias para pesquisa. A criação de modelos eficientes que possam utilizar esses dados de forma otimizada é, portanto, altamente vantajosa.

Além da qualidade e quantidade dos dados, o custo de processamento e o consumo de memória são fatores determinantes na escolha de um modelo. A análise de complexidade de tempo e espaço (CORMEN et al., 2009) permite avaliar a viabilidade de treinar um modelo em computadores com recursos limitados, possibilitando, inclusive, a construção simultânea de múltiplos modelos para comparação.

Finalmente, a acurácia do modelo é um requisito indispensável. Um modelo que não atende aos requisitos de desempenho computacional, ou que produz resultados imprecisos, pode levar a conclusões equivocadas. Portanto, a identificação de um modelo que combine alta acurácia, especialmente ao trabalhar apenas com dados de ocorrência, com um baixo custo computacional, é essencial para a realização de análises preliminares robustas e confiáveis.

1.3 Objetivo Geral

O objetivo deste trabalho é desenvolver um sistema flexível para a criação e avaliação de modelos de regressão (GAM, GLM e MARS), capaz de operar com conjuntos de dados arbitrários, contendo tanto variáveis contínuas quanto categóricas. O sistema deverá ser capaz de inferir, a partir das características dos dados, o tipo de variável resposta e, consequentemente, selecionar as métricas de avaliação mais adequadas.

1.3.1 Objetivos Específicos

Para alcançar o objetivo geral, foram definidos os seguintes objetivos específicos:

1. Implementar um fluxo de trabalho automatizado para o treinamento e teste dos seguintes modelos de regressão:
 - *Generalized Additive Model* (GAM);
 - *Generalized Linear Model* (GLM);
 - *Multivariate Adaptive Regression Spline* (MARS).
2. Desenvolver um mecanismo para a identificação automática do tipo de variável resposta (contínua ou categórica).
3. Implementar a seleção automática das métricas de avaliação com base no tipo de variável resposta identificada.

4. Realizar a avaliação comparativa do desempenho dos modelos implementados com base nas métricas selecionadas.

2 Revisão Bibliográfica

2.1 Modelos Computacionais

Modelos computacionais são representações simplificadas de fenômenos, que geram uma aproximação do evento real, com o objetivo de visualizar ou entender determinado fenômeno, codificados em alguma linguagem de programação para serem executados em um computador. Estes modelos podem ser criados por especialistas utilizando equações matemáticas ou, automaticamente, por meio de técnicas de inteligência artificial ([AUGUSTO, 2025](#)).

Ao processo de criação desses modelos, damos o nome de modelagem computacional, que pode ser aplicada em qualquer situação onde uma análise de um sistema complexo se faz necessária. Suas principais aplicações são encontradas nas seguintes áreas, como apresentado por ([COSME, 2025b](#)):

1. **Ciência e Pesquisa:** Permite o teste de hipóteses de maneira mais rápida e eficiente.
2. **Engenharia:** Essencial para projetos de larga escala, utilizada para testar estruturas antes de iniciar sua construção.
3. **Medicina:** Permite a modelagem de epidemias, prevendo como doenças podem se espalhar em uma dada população, ajudando a planejar métodos de controle.

O tipo da modelagem depende do tipo de fenômeno ou problema que queremos tratar. Os tipos principais, segundo ([COSME, 2025b](#)), são:

1. **Modelagem determinística:** O comportamento do sistema é previsível, onde os mesmos parâmetros de entrada sempre produzem os mesmos resultados. É mais comum nos campos da Física e da Engenharia, onde os fenômenos naturais seguem um conjunto de regras bem definido.
2. **Modelagem estocástica:** Inclui elementos de incerteza e aleatoriedade, e o sistema pode apresentar resultados diferentes para o mesmo conjunto de parâmetros de entrada. É comumente usada em áreas onde o acaso desempenha um papel importante, como na Biologia e na Economia.
3. **Modelagem dinâmica:** Focada em sistemas que mudam ao longo do tempo, é essencial em áreas como a Ecologia e a Epidemiologia, onde é preciso prever a evolução de sistemas biológicos ou a propagação de doenças.

2.1.1 Modelos Lineares

Modelos lineares preveem uma resposta linear utilizando como base a relação entre o resultado e as propriedades dadas como parâmetros. Por serem uma opção mais simples, possuem propriedades mais fáceis de serem entendidas e um tempo de desenvolvimento

mais curto quando comparados a outros tipos de modelos, como redes neurais ou árvores de decisão, empregadas para o mesmo problema (IBM, 2025).

A linearidade desses modelos implica que, matematicamente, a variação dos parâmetros independentes não possui relações entre si, e podem ser separados em dois grupos principais (ADALARDO, 2020).

- **Modelos de Regressão:** Este grupo é utilizado para modelar relações entre variáveis quantitativas, que são um conjunto de valores passíveis de representação numérica, indicando quantidade ou magnitude, com o intuito de estimar parâmetros, explicando relações ou para fazer predições.
- **Modelos de Análise de Variância:** Esses modelos têm como questão principal comparar a importância de fatores sobre o comportamento da variável de resposta, para encontrar a relação entre grupos de análise, de modo a identificar o que gera a diferença entre os grupos estudados.

Ambas as abordagens ao modelo linear gerarão uma regressão linear, que é um modelo matemático que descreve a relação entre as variáveis dependentes e independentes usadas, tendo a possibilidade de ser representado graficamente. Pode ser de dois tipos: simples ou múltipla.

Na regressão linear simples, queremos estimar os valores de a e b da equação da reta, $y = a + bx$, a partir de um conjunto de dados x e y , onde y representa a variável dependente e x a variável independente, que melhor represente a relação entre x e y . Em outras palavras, queremos estimar a inclinação da reta, que nos indica o efeito em y das mudanças ocorridas em x (CHEIN, 2019).

A essa reta é dado o nome de reta de regressão linear, que depende de cinco estatísticas básicas (CHEIN, 2019):

1. Média de X : $\bar{X} = \frac{1}{N} \sum_{i=1}^N X_i$;
2. Desvio padrão de X : $S_x = \sqrt{\frac{1}{N} \sum_{i=1}^N (X_i - \bar{X})^2}$;
3. Média de Y : $\bar{Y} = \frac{1}{N} \sum_{i=1}^N Y_i$;
4. Desvio padrão de Y : $S_y = \sqrt{\frac{1}{N} \sum_{i=1}^N (Y_i - \bar{Y})^2}$;
5. Correlação de X e Y : $r = \frac{1}{n} \sum_{i=1}^N \frac{X_i - \bar{X}}{S_x} \cdot \frac{Y_i - \bar{Y}}{S_y}$

Com estas estatísticas, podemos traçar a reta de regressão, sabendo que esta passa pelo ponto médio $(\bar{X}, \bar{Y})$. A inclinação da reta será dada por:

$$\beta_1 = \frac{r \cdot S_y}{S_x} \quad (2.1)$$

E o intercepto da reta de regressão, onde a reta corta um dos eixos do plano cartesiano, será dado por:

$$\beta_0 = \bar{Y} - \beta_1 \bar{X} \quad (2.2)$$

Assim, resultamos na seguinte equação:

$$Y = \beta_0 + \beta_1 X \quad (2.3)$$

Onde:


- (X) é a variável independente;
- (Y) é a variável dependente;
- (β_0) é o intercepto da reta;
- (β_1) é a inclinação da reta.

Porém, a equação 2.3 ainda não proporciona os valores de Y , mesmo possuindo os valores para β_0 e β_1 , visto que, em ocorrências do mundo real, não é apenas a variável X que afeta os valores de Y . Assim, incluímos um termo de erro ϵ , que é o erro que se comete ao estimar os valores de Y por meio da variável X (CHEIN, 2019).

$$Y = \beta_0 + \beta_1 X + \epsilon \quad (2.4)$$

Agora, com a equação 2.4, podemos criar a reta de regressão, que pode ser representada graficamente, possuindo uma estrutura semelhante ao gráfico a seguir:

Figura 1 – Regressão Linear Simples



Fonte: EBAC (2023)

A equação 2.4 pode ser escrita de forma mais geral. Visto que em nossos dados podemos trabalhar com conjuntos de valores, agrupando valores de Y distintos para cada valor de X . Por exemplo, dados que representam a qualidade de vida nos estados brasileiros com o número de postos de saúde. Assim, a equação 2.4 ficaria (CHEIN, 2019):

$$Y_i = \beta_0 + \beta_1 X_i + \epsilon_i \quad (2.5)$$

Onde:

- (i) representa um agrupamento de dados, um estado brasileiro, seguindo o exemplo anterior;
- (Y_i) é a variável dependente;
- (X_i) é a variável independente, que representaria o número de postos de saúde em um dado estado;
- (β_0) é o intercepto;
- (β_1) é a inclinação e o efeito médio de X_i sobre Y_i ;
- (ϵ) é o erro médio ao se estimar Y_i por meio de X_i ;

Já quando tratamos da regressão linear múltipla, leva-se em conta que outros fatores podem afetar a variável de resposta, os quais também podem ser correlacionados com a variável independente. A fórmula para este modelo de regressão pode ser representada da seguinte forma, onde temos k variáveis explicativas ([CHEIN, 2019](#)):


$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k + \epsilon \quad (2.6)$$

Onde:

- (β_0) é o intercepto;
- $(\beta_1, \dots, \beta_k)$ são "inclinações", mesmo que, na prática, não sejam inclinações da função;
- (ϵ) é o termo de erro.

Aqui, temos β_1 até β_k como coeficientes parciais da regressão ([CHEIN, 2019](#)). Neste caso, a visualização por meio de um gráfico fica comprometida, visto que temos um número k de X . Para ilustrar, usemos uma situação onde temos dois X ; aqui, podemos representar os valores por um gráfico de três dimensões.

Figura 2 – Regressão Linear Múltipla



Fonte: [Novak \(2022\)](#)

Quando temos mais de dois valores de X , a representação gráfica fica confusa para o entendimento humano, mas ainda podemos tratar o problema como uma reta.

2.1.2 Métodos de avaliação de Modelos Computacionais

Antes de apontarmos as métricas, precisamos explicar os tipos de classificação que um modelo pode alcançar, categorizando sua previsão como correta ou não. Para modelos categoricos utilizamos a matriz de confusão, e quando nosso modelo atua com dados contínuos, utilizamos as metrcas MAE e RMSE.

2.1.2.1 MAE e RMSE

O erro medio absoluto (MAE), é um dos vários modos de comprar uma predição com seus valores reais, algumas de suas variações são, erro médio absoluto escalonado (MASE), erro médio absoluto logarítmico (MALE) e erro médio quadrático. Estes metodos resumem o modelo, desconsiderando a direção de superestimação e subestimação, para levar estes pontos em conta o poderia ser utilizado a diferença media com sinal ([WILLMOTT; MATSUURA, 2005](#)).

A representação matematica do MAE, é a soma dos erros absolutos dividido pelo tamanho da amostra utilizada.

$$MAE = \frac{\sum_{i=1}^n |y_i - x_i|}{n} \quad (2.7)$$

Em outras palavras o MAE é a diferença absoluta entre X e Y , onde temos como alvo diminuir o valor do MAE assim representando um modelo melhor.

Já o erro quadrático médio (RMSE), é a média quadrática da diferença entre os valores observados e os previstos, servindo para agregar as magnitudes dos erros nas

previsões para vários pontos de dados em uma única medida, sendo uma medida de precisão, usada para comparar os erros de previsão de diferentes modelos para um conjunto de dados Específicos (HYNDMAN; KOEHLER, 2006).

2.1.2.2 Matriz de Confusão

Tabela 1 – Matriz de Confusão

	Verdadeiro Positivo	Verdadeiro Negativo
Positivo Previsto	Positivo Verdadeiro	Falsos Positivos
Negativo Previsto	Falsos Negativos	Negativos Verdadeiros

Fonte: (FILHO, 2023)

Onde:

- **Positivos Verdadeiros:** São as classificações positivas corretas;
- **Falsos Positivos:** São positivos que foram erroneamente classificados como negativos;
- **Falsos Negativos:** São negativos que foram erroneamente classificados como positivos;
- **Negativos Verdadeiros:** São as classificações negativas corretas;

Existem várias métricas para se avaliar a qualidade de um modelo computacional, sendo os métodos mais comuns a acurácia, precisão, recall, F1-Score e a área da curva ROC (AUC-ROC) (DUARTE, 2024), onde:

- **Acurácia:** Uma métrica simples e amplamente utilizada que mede a proporção de previsões corretas feitas pelo modelo;
- **Precisão:** Uma métrica que mede a proporção de previsões positivas corretas feitas pelo modelo, muito utilizada quando um falso positivo agrega um custo muito alto;
- **Recall:** Uma métrica que mede a proporção de exemplos positivos que foram corretamente identificados pelo modelo;
- **F1-Score:** É uma média harmônica entre a Precisão e o Recall, que fornece um equilíbrio entre essas duas métricas, utilizado quando se quer levar em consideração tanto os falsos positivos quanto os falsos negativos;
- **AUC-ROC:** Avalia o desempenho de modelos de classificação binária em diferentes limites de decisão, onde quanto maior o valor, melhor o modelo separa essas classes.

Como cada métrica possui um campo de atuação, para o problema abordado neste trabalho, as relevantes são a acurácia e a precisão. A precisão apresenta uma métrica de avaliação onde se aceita o erro de um falso negativo, pois o erro de um falso positivo é algo prejudicial à previsão. Isso, fazendo com que um local sem ocorrência da espécie analisada pelo modelo possa ser indicado como um lugar de ocorrência, torna a métrica por acurácia mais confiável neste caso.

2.1.2.3 Acurácia

A acurácia é um modo de avaliar a performance de um modelo, identificando se seus resultados podem ser considerados válidos ou não. Para chegarmos na acurácia, utilizamos a seguinte fórmula:

$$A = \frac{PC}{TP} \quad (2.8)$$

Onde:

- (A) é a Acurácia;
- (PC) é o total de Previsões Corretas, encontrado pela soma de *PositivosVerdadeiros* + *NegativosVerdadeiros*;
- (TP) é o Total de Previsões, encontrado pela soma de $PC + \textit{FalsosVerdadeiros} + \textit{FalsosNegativos}$.

Como a acurácia incorpora por completo a matriz de confusão 1, em um conjunto de dados equilibrado, com uma quantidade de exemplos semelhante para as duas classes, ela pode ser usada como uma medida geral da qualidade de um modelo (DEVELOPERS, 2024).

Onde temos mais exemplos de uma classe do que de outras, é importante considerar outras métricas de avaliação, já que esses modelos são considerados desbalanceados (FILHO, 2023).

2.1.3 Modelos de Distribuição de Espécies

Definimos um Modelo de Distribuição de Espécies (SDM - Species Distribution Model) como um modelo que relaciona dados de distribuição de espécies com informações sobre as características ambientais e/ou espaciais de certas localidades, podendo ser usados para entender e/ou prever a distribuição de uma espécie em uma dada localidade (ELITH; LEATHWICK, 2009).

SDMs contemporâneos combinam conceitos de ecologia e história natural com os avanços mais recentes em estatística e tecnologia da informação. As raízes desses modelos são encontradas nos estudos mais antigos que descrevem padrões biológicos em termos de relações com a geografia e/ou gradientes ambientais, e estudos que indicam a resposta individual de espécies para seus ambientes, provendo um forte argumento conceitual para se modelar espécies de modo individual (ELITH; LEATHWICK, 2009).

Segundo (OLIVER, 2024), as principais fontes de informações para a criação destes modelos são:

- Dados de ocorrência: Geralmente coordenadas de latitude e longitude onde a espécie foi observada, conhecidas como dados de ocorrência. Alguns modelos fazem uso de dados de ausência, que são coordenadas geográficas onde se sabe que a espécie não ocorre;

- Dados ambientais: São a descrição do ambiente, podendo conter medições de temperatura e precipitação, como também, a ocorrência e ausência de outras espécies, como predadores, competidores ou fontes de alimento.

Dentro dos SDMs, temos vários frameworks de modelagem, sendo os mais utilizados o Generalized Linear Model (GLM), o Generalized Additive Model (GAM) e o Multivariate Adaptive Regression Spline (MARS), que são encontrados nos softwares mais amigáveis ao usuário e bem documentados (NORBERG et al., 2019), assim como podem ser encontrados em bibliotecas de linguagens de programação, como R, nas bibliotecas mda, onde encontramos o GLM e o GAM (HASTIE et al., 2024), e mgcv, onde encontramos o MARS (WOOD, 2025).

2.1.3.1 GLM - Generalized Linear Model

Generalized Linear Models (GLMs) agrupam uma grande quantidade de modelos discretos e contínuos, sendo particularmente úteis para se trabalhar com dados discretos. São uma extensão de General Linear Models, apresentada por Nelder e Wedderburn (1972), que consiste na inserção da família exponencial de distribuições de erro junto com a distribuição normal (PAUL; SAHA, 2007).

Ao contrário dos modelos lineares clássicos, assim como o General Linear Model, que propõem uma distribuição Gaussiana (normal) e uma função de ligação dos valores de X e Y , os GLMs permitem que a função de distribuição seja alguma da família de distribuições exponenciais (Gaussiana, Poisson ou Binomial), e a função de ligação pode ser qualquer função monotônica diferenciável, como a logarítmica (GUISAN; EDWARDS; HASTIE, 2002).

No GLM, as variáveis de predição X_j , onde $j = 1, \dots, p$ com p sendo a quantidade de X s, são combinadas para se formar um preditor linear (LP), que é relacionado ao valor esperado $\mu = E(Y)$ da variável de resposta Y através de uma função de ligação $g()$ (GUISAN; EDWARDS; HASTIE, 2002). Assim, podemos chegar à seguinte fórmula:

$$g(E(Y)) = LP = \alpha + X^T \beta \quad (2.9)$$

Onde:

- α : é uma constante, chamada de intercepto;
- X : é um vetor de p preditores, $(X_1, \dots, X_p)$;
- β : é um vetor de p coeficientes de regressão, um para cada preditor, $(\beta_1, \dots, \beta_p)$.

Assim, escrevemos o modelo para variáveis X e Y genéricas. Os termos correspondentes para uma dada observação i da amostra são (GUISAN; EDWARDS; HASTIE, 2002):

$$g(\mu_i) = \alpha + \beta_1 X_{i1} + \beta_2 X_{i2} + \dots + \beta_p X_{ip} \quad (2.10)$$

Aqui, a variância de Y depende de $\mu = E(Y)$ através da função de variância $V(\mu)$, dado $Var(Y) = \phi V(\mu)$, onde ϕ (phi) é o parâmetro de dispersão. Quando se espera um ϕ

maior que o valor antecipado dada a distribuição escolhida, o parâmetro de escala pode ser estimado utilizando-se de quasi-likelihood (GUISAN; EDWARDS; HASTIE, 2002).

Por sua vez, quasi-likelihood é um método de se generalizar a abordagem por likelihood-based para GLMs, permitindo que se estimem os valores de β de tal forma que não é necessário se especificar uma distribuição para a saída. Normalmente, é utilizado como um mecanismo para lidar com dados muito dispersos, ou quando não se deseja fazer afirmações sólidas de distribuição sobre as variáveis de saída (SPICKER, 2025).

2.1.3.2 GAM - Generalized Additive Model

Gerados a partir do GLM, este modelo possui uma automatização para se identificar os termos de polinômio apropriados e as transformações dos preditores que melhoram a qualidade do modelo linear. Logo, podemos dizer que os GAMs estão aninhados dentro dos GLMs, que por sua vez estão aninhados em modelos lineares, LM (GUISAN; EDWARDS; HASTIE, 2002):

$$LM \subset GLM \subset GAM \quad (2.11)$$

GAMs são parametrizados como os GLMs, porém alguns preditores podem ser modelados de modo não parametrizado em adição a termos lineares e polinomiais para outros preditores. Um passo crucial para aplicar GAMs é selecionar o nível apropriado de "suavização" para os preditores.

Nestes, substitui-se a função de predição linear $\eta = \sum_1^p \beta_j X_j$ pela função de predição aditiva $\eta = \sum_1^p s_j(X_j)$, onde $s_j(X_j)$ é uma função de suavização do valor X_j . A forma assumida para a estimativa pelo modelo de regressão linear possui a seguinte característica (HASTIE; TIBSHIRANI, 1986):

$$E(Y|X_1, X_2, \dots, X_p) = \beta_0 + \beta_1 X_1 + \dots + \beta_p X_p. \quad (2.12)$$

Enquanto no GAM, generaliza-se o modelo de regressão linear, tornando a equação 2.12:

$$E(Y|X_1, X_2, \dots, X_p) = s_0 + \sum_{j=1}^p s_j(X_j) \quad (2.13)$$

Como exemplo, tomemos o caso de um preditor simples. Neste, nosso modelo seria:

$$E(Y|X) = s(X) \quad (2.14)$$

Para estimarmos $s(x)$ a partir de nossos dados, podemos usar uma estimativa razoável de $E(Y|X = x)$. Uma dessas classes de estimativas são as estimativas médias locais, $\hat{s}(x_i) = Ave_{j \in N_i}(Y_j)$, onde Ave representa uma operação de média, como a média, e N_i é a vizinhança de x_i , os valores x que estão próximos a x_i . Em associação com a vizinhança, temos o tamanho w da janela, isto é, a proporção de pontos contidos em cada janela (HASTIE; TIBSHIRANI, 1986).

Se assumirmos que x é um valor inteiro e que wn é ímpar, então a abrangência da vizinhança w mais próxima simétrica conterá wn pontos, o i -ésimo ponto mais $\frac{(wn-1)}{2}$

pontos em cada lado do i -ésimo ponto. Assumindo que os dados estão ordenados de forma crescente em x , uma definição formal seria (HASTIE; TIBSHIRANI, 1986):

$$N_i = \max \left\{ i - \frac{wn - 1}{2}, 1, \dots, i - 1, i, i + 1, \dots, \min \left\{ i + \frac{wn - 1}{2}, n \right\} \right\} \quad (2.15)$$

A vizinhança fica truncada próxima aos pontos finais se os pontos $\frac{wn-1}{2}$ não estão disponíveis. A abrangência de w controla a suavidade dos resultados estimados e geralmente é escolhida com base nos dados a serem usados (HASTIE; TIBSHIRANI, 1986). Se $\bar{Ave}$ representar a média aritmética, então $\hat{s}(\cdot)$ é a running lines smoother, e sua definição para estimar valores de x é:

$$\hat{s}(x_i) = \hat{\beta}_{0i} + \hat{\beta}_{1i}x_i \quad (2.16)$$

Onde $\hat{\beta}_{0i}$ e $\hat{\beta}_{1i}$ são as estimativas por least square para os pontos de dados de N_i :

$$\begin{aligned} \hat{\beta}_{1i} &= \frac{\sum_{j \in N_i} (x_j - \bar{x}_i)y_j}{\sum_{j \in N_i} (x_j - \bar{x}_i)^2}, \\ \hat{\beta}_{0i} &= \bar{y}_i - \hat{\beta}_{1i}\bar{x}_i, \\ \bar{x}_i &= \frac{1}{n} \sum_{j \in N_i} x_j, \\ \bar{y}_i &= \frac{1}{n} \sum_{j \in N_i} y_j \end{aligned} \quad (2.17)$$

Outros métodos de estimar $E(Y|X)$ poderiam ser usados, acarretando a mudança do custo computacional do modelo, podendo trabalhar tão bem quanto ou melhor do que o running lines smoother (HASTIE; TIBSHIRANI, 1986).

2.1.3.3 MARS - Multivariate Adaptive Regression Spline

O foco na modelagem por regressão é estimar uma função $\hat{f}(x_1, \dots, x_n)$, que melhor se assemelhe à função $f(x_1, \dots, x_n)$, que descreve a relação entre as propriedades de um dado fenômeno e o seu resultado real (FRIEDMAN, 1991).

$$y = f(x_1, \dots, x_n) + \epsilon \quad (2.18)$$

A função de n -dimensões f captura a relação de predição de y em $x_1, \dots, x_n$, onde o alvo da análise regressiva é usar os dados para construir a função $\hat{f}(x_1, \dots, x_n)$ que serve como uma aproximação razoável para $f(x_1, \dots, x_n)$ sobre um domínio D de interesse. Onde MARS provê uma abordagem natural para a modelagem de variáveis categóricas, variáveis aninhadas (variável que contém outra variável) e valores faltantes (FRIEDMAN; ROOSEN, 1995).

O procedimento MARS é baseado em uma generalização de métodos de spline para ajuste de funções. Consideramos o caso de apenas um preditor, $x(n = 1)$, para se estimar a função $f(x)$. Uma função spline de aproximação $\hat{f}_q(x)$ é obtida por dividir a abrangência de valores de x em $k + 1$ regiões separadas por k pontos (FRIEDMAN; ROOSEN, 1995).

$$\hat{f}_q(x) = \sum_{k=0}^{k+q} a_k B_k^{(q)}(x) \quad (2.19)$$

Onde $\{B_k^{(q)}(x)\}_0^{k+q}$ é um conjunto de funções base que englobam todo o espaço da função spline de ordem q e a_k é o valor do coeficiente de expansão, sendo sem limitadores (FRIEDMAN; ROOSEN, 1995).


A base mais popular é a 'B-spline', que possui superioridade em número de propriedades usadas em conjunto com o least-squares fitting. A 'B-spline' é definida por $K + 2$ locais de pontos adjacentes, onde a função limitadora tem o maior suporte, mas é definida cada uma por um único local. Para a seleção destas funções base, um grupo de resultados não válidos será removido. Se tivermos um modelo aditivo, onde

$$\hat{f}(x) = \sum_{j=1}^n f_j(x_j) \quad (2.20)$$

fosse considerado adequado, qualquer função que envolvesse mais de uma variável se tornaria ilegítima para inclusão no modelo (FRIEDMAN; ROOSEN, 1995).

Em outras palavras, podemos definir um spline como a aproximação de uma curva de formato complexo utilizando o menor número possível de retas, sendo essa quantidade de retas o parâmetro q , como pode ser visto na figura a seguir:

Figura 3 – Curva Spline



Fonte: (ZHANG; GOH, 2013)

O algoritmo MARS usa uma estratégia de passos forward/backward para produzir seu conjunto de funções base. A parte de forward é um processo recursivo. A cada iteração, simultaneamente constrói uma lista expansiva de funções base a serem consideradas e então decide quais considerar naquele passo, repetindo-se até que uma quantidade relativamente grande de funções base seja selecionada.

Um conjunto final de funções base de tamanho apropriado é então selecionado por meio de um procedimento de seleção de subconjunto de variáveis passo a passo regressivo,

usando as funções base produzidas pelo algoritmo progressivo como 'variáveis' candidatas (FRIEDMAN; ROOSEN, 1995).

O passo de forward começa com uma única função base no modelo:

$$B_0(x) = 1 \quad (2.21)$$

Apos a M -ésima iteração, teremos $2M + 1$ funções:

$$\{B_m(\mathbf{x})\}_0^{2M} \quad (2.22)$$

No modelo, cada iteração ($M + 1$) adiciona duas novas funções base:

$$\begin{aligned} B_{2M+1}(x) &= B_{l(M+1)}(x)[+(x_{v(M+1)} - t_{M+1})]_+^q \\ B_{2M+2}(x) &= B_{l(M+1)}(x)[-(x_{v(M+1)} - t_{M+1})]_+^q \end{aligned} \quad (2.23)$$

Aqui, $B_{l(M+1)}(x)$ é uma das $2M + 1$ funções base já selecionadas, $0 \leq l(M+1) \leq 2M$, $v(M+1)$ é uma variável preditora, não representada em $B_{l(M+1)}(x)$, e t_{M+1} é um ponto nesta variável. Os três parâmetros $l(M+1)$, $v(M+1)$ e t_{M+1} que definem as duas novas funções base são escolhidos para serem os que melhoram o fitting do "novo" modelo com os dados.

Para pequenas amostras, o algoritmo MARS tentará produzir modelos que envolvem interações de baixa ordem e, com grandes amostras, *ele favorecerá interações de alta ordem para os possíveis candidatos*.

2.2 Linguagem R

R foi desenvolvido e pensado como uma linguagem e ambiente para computação estatística e gráficos. Possui a capacidade de trabalhar com vários processos estatísticos, como modelagem linear e não-linear, testes clássicos de estatística, séries temporais, entre outros, e ser altamente extensível (THE..., 2025).

Devido ao seu desenvolvimento focado em aplicações de computação estatística, ser semelhante e compatível com a linguagem S já existente, e capaz de atuar com códigos feitos nas linguagens C, C++ e Fortran (THE..., 2025), tornou o R uma linguagem popular dentro da área de computação estatística (AWARI, 2022).

O ambiente do R pode ser facilmente incrementado, utilizando-se de bibliotecas, nomeadas como packages. Por padrão, temos oito packages que são encontrados junto da distribuição comum do R. Outros packages podem ser encontrados em sites especializados na distribuição dos mesmos (THE..., 2025).

Além de ser de fácil incrementação, o ambiente R possui uma interface de desenvolvimento gratuita, o R Studio, onde a utilização da linguagem fica concentrada em uma única aplicação, facilitando a visualização dos dados, gráficos, alteração e manutenção do código e packages (RSTUDIO..., 2025).

2.2.1 Packages

Packages, também conhecidos como bibliotecas ou pacotes, dentro do cenário de computação, referem-se a agrupamentos de códigos desenvolvidos por terceiros ou por si mesmo, para encapsular alguma atividade ou processo que pode ser utilizado em mais de um projeto.

Como exemplo, podemos utilizar os packages *mda* e *mgcv*, presentes neste trabalho. O package *mda* engloba funções para se aplicar um grupo de modelagem de dados, sendo estes o Mixture and Flexible Discriminant Analysis, Multivariate Adaptive Regression Splines (MARS) e Vector-response Smoothing Splines (HASTIE et al., 2024). O *mgcv* engloba Generalized Additive Model e algumas de suas variações, Generalized Cross Validation e similares (WOOD, 2025). Os Generalized Linear Models podem ser encontrados na biblioteca *stats*, que vêm por padrão na linguagem R.

Para demonstrar o uso de um package, tomemos a utilização da função referente ao GAM encontrada no package *mgcv*, um conjunto de dados criado contendo pontuações médias em ciências por país, segundo o Programa Internacional de Avaliação de Estudantes (PISA) de 2006, junto ao RNB per capita (Paridade do Poder de Compra, valores de 2005), Índice de Educação, Índice de Saúde e Índice de Desenvolvimento Humano, segundo dados da ONU (CLARK, 2025).

Listing 2.1 – Exemplo uso de package

```
1 library(mgcv)
2 pisa = read_csv('data/pisasci2006.csv')
3 mod_gam = gam(Overall ~ s(Income, bs = "cr"), data = pisa)
```

Fonte: Clark (2025)

O código 2.1 gera um Generalized Additive Model, determinando os termos de suavização pela função *s()* com o tipo de suavização sendo a splines de regressão cúbicas (CLARK, 2025).

A linha *library(mgcv)* é a responsável por indicar qual package estamos usando, neste caso o *mgcv*, mas poderia ser outro ou mais de um package. Assim, quando chamamos a função *gam()*, a mesma é buscada dentro do package. E seu funcionamento interno é mascarado para o usuário. Precisamos apenas "configurar" alguns parâmetros, como a *data*, os dados que o modelo irá utilizar, e quais campos dos dados iremos usar *Overall ~ s(Income, bs = "cr")*.

Estes packages permitem ao usuário apenas chamar a função que representa o processo a ser executado, não precisando se preocupar com os pormenores da execução em si, apenas passar os parâmetros necessários de modo correto.

2.3 Trabalhos relacionados

O estudo "A comprehensive evaluation of predictive performance of 33 species distribution models at species and community levels"(NORBERG et al., 2019) teve como foco a avaliação de 33 modelos distintos de distribuição de espécies, questionando a performance de cada um trabalhando com comunidades e com espécies específicas.

Neste trabalho, os autores identificam os parâmetros de cada modelo e seus tipos, mostrando quais são esperados que trabalhem melhor com comunidades ou com espécies únicas, identificando dentro dos modelos selecionados que os cinco melhores são os HMSC.3, GLM.5, MISTN.1, MARS.1 e GNN.1.

Onde a performance final é influenciada por três fatores: o modelo escolhido, o foco de predição e a qualidade dos dados. O modelo que obteve a melhor performance quando considerado todas as espécies (comunidade) foi o HMSC.1, e quando apenas uma espécie foi levada em consideração, o modelo GLM.4 teve uma performance melhor.

Podemos ver neste trabalho dois dos três tipos de modelos de SDM mais comuns: GLM (GLM.4 e GLM.5) e MARS (MARS.1), mostrando que, além do acesso relativamente fácil a estes e de possuírem um software bem documentado e amigável (NORBERG et al., 2019), sua qualidade de performance ajuda a torná-los modelos relevantes.

No estudo "Generalized linear and generalized additive models in studies of species distributions: setting the scene"(GUISAN; EDWARDS; HASTIE, 2002), os autores fazem uma breve revisão sobre modelos lineares, GLMs e GAMs, apresentando algumas de suas características e as relações entre os mesmos.

Uma descrição mais teórica dos modelos GLM, GAM e MARS são encontradas nos seguintes trabalhos, respectivamente: "The generalized linear model and extensions: a review and some biological and environmental applications"(PAUL; SAHA, 2007), "Generalized Additive Models"(HASTIE; TIBSHIRANI, 1986) e "An introduction to multivariate adaptive regression splines"(FRIEDMAN, 1991).

Nestes, temos uma dissertação sobre a parte matemática dos modelos, como é feita a inferência de cada um de seus parâmetros e como o mesmo atua sobre os dados de entrada. Em alguns, temos exemplos de uso de cada modelo e suas variações, mostrando onde estas são diferentes do modelo que é tratado no estudo.


3 Desenvolvimento

Neste capítulo, será abordada a arquitetura e o processo de desenvolvimento de uma aplicação avaliadora de possíveis modelos computacionais preditivos, abrangendo as ferramentas e bibliotecas utilizadas, os algoritmos desenvolvidos e a execução do projeto.

3.1 Arquitetura

A arquitetura proposta para a aplicação foi idealizada para ser robusta e adaptável, tornando a aplicação utilizável com e sem conexão à rede de internet, assim como a possível inserção de novos modelos preditivos. Sua estrutura segue como referência o seguinte esquema, que pode ser encontrado no Anexo A.

Figura 4 – Arquitetura do sistema



Fonte: Elaboração do autor


No sistema idealizado, a parte de controle da aplicação é responsabilidade da classe App. A classe `call_model` age como uma interface entre o App e os modelos disponíveis, responsável por informar quais modelos estão disponíveis, e rodar seus respectivos treinos e testes.

Essa mesma interface possibilita a adição de novos modelos, sendo necessário se adequar ao modo como os dados são passados e como o sistema espera encontrar seus

modelos treinados e respectivas respostas.

Os modelos implementados possuem um processo de treino semelhante. Seus fluxos são representados nos seguintes diagramas de sequência, assim como a sua avaliação.

Figura 5 – Diagrama de Sequência - MODELO



Fonte: Elaboração do autor

Tanto para os modelos disponíveis quanto para os dados, o sistema possui a capacidade de armazenar os mesmos em um serviço de armazenamento pela internet, quanto em um armazenamento local, tornando o mesmo independente de uma conexão contínua com a internet.

3.2 Recursos tecnológicos

Nesta seção, são apresentados os recursos utilizados para a confecção da aplicação, assim como uma breve justificativa em relação à escolha de cada um.

- Python 3.10.0: Linguagem de alto nível, interpretada, com uma forte presença no campo da Ciência de Dados, Aprendizado de Máquina e Inteligência Artificial. Esta linguagem foi escolhida por suas bibliotecas que facilitam o tratamento de dados e a integração de *scripts* em outras linguagens de programação.

- R 4.1.2: Linguagem de alto nível, interpretada, assim como o Python, possui uma forte presença na Ciência de Dados e Aprendizado de Máquina, mas se destaca também no campo da Análise Estatística. Esta linguagem foi escolhida por sua implementação robusta dos modelos GAM, GLM e MARS.
- Streamlit 1.48.1: Biblioteca para a linguagem Python, desenvolvida com o intuito de facilitar a criação e o compartilhamento de aplicações web, com foco em Aprendizado de Máquina e Ciência de Dados. Utilizada para a construção da interface gráfica do projeto.
- Supabase: Plataforma de *Backend as a Service* (BaaS) de código aberto, sendo seus principais serviços: banco de dados PostgreSQL, APIs instantâneas, Autenticação e Armazenamento. Escolhida por sua capacidade de Armazenamento e a fácil integração com a linguagem Python.
- subprocess: Biblioteca nativa do Python, que possibilita que durante a execução de um *script* Python, seja chamado outro *script* ou programa. Utilizado para a integração do *Python* com os *scripts* em R.

3.3 Dados

A aplicação foi desenvolvida para aceitar dados armazenados em um arquivo no formato *.csv* (Comma-separated value), com a capacidade de armazenar estes dados em um serviço de armazenamento online ou de modo local.

O sistema se encarrega de conver os nomes das colunas para um formato aceitado pelo sistema e não utilizando entradas com dados faltantes que podem atrapalhar na criação dos modelos e seus respectivos testes. Para a separação dos dados, o sistema os divide em dois grupos, dados para teste e dados para treino, de um modo aleatório, separando 80% dos dados para treino e 20% dos dados para teste.

Os dados são utilizados no sistema para inferir quais testes devem ser usados para avaliar o modelo, visto que, se os mesmos forem dados contínuos, as métricas avaliativas são diferentes das usadas na situação onde os dados são categóricos. Assim como o nome das colunas é usado para selecionar quais serão os parâmetros dependentes e independentes.

3.3.1 Armazenamento

Os dados locais são armazenados dentro da subpasta *dados* encontrada dentro da pasta *data*, e os dados que estão armazenados no *Supabase* podem ser encontrados no *storage* dentro da pasta *dados*.

Para os modelos, seu armazenamento ocorre de modo semelhante. Quando em um cenário local, são encontrados na pasta *models*, e quando em um funcionamento online, os modelos são encontrados no *storage*, porém na pasta *models*.

A aplicação sempre tenta entrar em modo online, tentando se conectar com o *Supabase*. Se falhar, inicia automaticamente em modo offline e passa a procurar os arquivos em suas pastas locais. Do contrário, sempre busca no *storage* configurado no *Supabase*.

3.4 Implementação

O aplicativo foi majoritariamente desenvolvido utilizando a linguagem de programação Python, e os modelos são implementados utilizando a linguagem de programação R, assim como os métodos de avaliação.

A parte principal da aplicação foi implementada no arquivo *app.py*, onde é tratada a conexão com o *Supabase*, assim como o preparo para o treino de um novo modelo.

A conexão é tratada no seguinte trecho de código:

```

1     try:
2         db = database.Connection()
3         if db.offline_mode:
4             st.warning("Executando em modo offline. Usando dados
                           locais.")
5         else:
6             st.success("Conectado ao Supabase")
7     except Exception as e:
8         st.error(f"Erro na conexao: {e}")
9         st.stop()

```

Onde, se não for possível a conexão com o Supabase por qualquer motivo, o aplicativo é iniciado no modo offline, utilizando dos dados e modelos disponíveis localmente.

A parte visual da aplicação é gerenciada pela biblioteca *Streamlit*.

A utilização dessa biblioteca pode ser vista nas funções utilizadas para gerar os campos de seleção, que serão variados dependendo do conteúdo disponível.

```

1     sb_response = widgets.creat_selectbox(
2         lst_param,
3         'Selecione o parametro de resposta (variavel dependente)'
4     )

```

Onde o funcionamento da biblioteca *Streamlit* está encapsulado pelo *script widgets*. Para ver com maiores detalhes, podemos usar a função utilizada no código visto anteriormente.

```

1     def creat_selectbox(list: list, label: str|None):
2         return st.selectbox(label, list)

```

Assim que o programa tem um modelo selecionado, podemos escolher os parâmetros de resposta e os preditores. Isso está implementado na seguinte parte do programa:

```

1     col1, col2 = st.columns(2)
2
3     with col1:
4         sb_response = widgets.creat_selectbox(
5             lst_param,
6             'Selecione o parametro de resposta (variavel
                           dependente)'
7         )
8
9     with col2:

```

```

10     predictor_options = [col for col in lst_param if col !=
11         sb_response] if sb_response else lst_param
12     sb_predictor = widgets.creat_multiselect(
13         predictor_options,
14         'Selecione um ou mais preditores (variaveis
            independentes)'
    )

```

Tendo os parâmetros selecionados, o treino do modelo pode ser efetuado. Para isso, é necessário utilizar as funções implementadas dentro do *script call_model*. Seu uso pode ser visto dentro da seguinte parte do *script app.py*:

```

1     try:
2         result = src.call_model.run_model(db_data, data, model,
3             sb_response, sb_predictor)
4         results.append({
5             'modelo': model,
6             'status': 'Sucesso',
7             'resultado': result
8         })
9         st.success(f'{model} executado com sucesso!')
10    except Exception as e:
11        results.append({
12            'modelo': model,
13            'status': f'Erro: {str(e)}',
14            'resultado': None
15        })
16        st.error(f'Erro ao executar {model}: {str(e)}')

```

Tendo os modelos treinados, a lógica dos testes começa no *script testes.py* encontrado na pasta *pages*. Este, por sua vez, chama o *script* em R responsável por gerenciar os testes, através da função *run_teste*.

```

1     for avaliableModel in db_avaliableModels:
2         model = f"modelos/{avaliableModel}"
3
4         src.call_model.run_teste(model)

```

A função *run_teste* chama o seguinte *script* em R:

```

1     library(jsonlite)
2
3     source("src/score_categorico.r")
4     source("src/score_continuo.r")
5
6     args <- commandArgs(trailingOnly = TRUE)
7
8     if (length(args) < 1) {
9         stop("0 argumento passado nao e valido.", call. = FALSE)
10    }
11
12    json_file <- args[1]
13    json_dado <- fromJSON(json_file)

```



```

14
15     model <- readRDS(json_dado$model)
16     data_test <- read.csv(json_dado$data_name)
17
18     response_col_name <- json_dado$response_name
19     val_response <- data_test[response_col_name]
20
21     unic_values <- length(unique(val_response))
22     all_values <- length(val_response)
23
24     percent_unic <- (unic_values * 100) / all_values
25
26     col_class <- class(val_response)
27
28     if ((col_class == "factor" || col_class == "character") &&
29         percent_unic < 10){
30         score_categorico(model, data_test, json_dado)
31     }else {
32         score_continuo(model, data_test, json_dado)
33     }

```

Por sua vez, esse *script* em R identifica qual método de avaliação será usado, com base no tipo de dados, que é inferido a partir da porcentagem de valores únicos e o tipo de classe da coluna sendo avaliada.

Tendo avaliado os modelos, o *script* retorna ao aplicativo as métricas usadas e seus respectivos valores.

3.4.1 Modelos

Para se gerar um modelo, primeiro precisamos escolher qual dataset será utilizado e qual o tipo de modelo a ser gerado. Aqui, é possível escolher mais de um tipo de modelo para criação em conjunto.

O código para gerar um modelo possui alguns pontos importantes, a forma como ele recebe os dados para treinar o modelo e como deve ser o retorno para o aplicativo. As informações necessárias são passadas através de argumentos de comando e, para extraí-los, usamos a seguinte parte do *script* em R:

```

1     args <- commandArgs(trailingOnly = TRUE)
2
3     if (length(args) < 3){
4         stop("0 argumento passado nao e valido.", call. = FALSE)
5     }
6
7     file_name <- args[1]
8     response <- args[2]
9     predictors <- args[3:length(args)]

```

Tendo os dados e o tipo do modelo sido escolhidos, o sistema nos informa quais os parâmetros podem ser utilizados como preditores e respostas, permitindo a escolha de um número variado de variáveis em ambos os casos.

É de responsabilidade do *script* que gera o modelo criar a equação para a geração do mesmo. Tomando como exemplo, temos o *script* que gera um modelo GLM feito em R:

```

1 response_original <- response
2 predictors_original <- predictors
3 response <- make.names(response)
4 predictors <- make.names(predictors)
5
6 string <- paste(response, "~", paste0(predictors, collapse =
7   "+"))
8 formula <- as.formula(string)

```

Neste trecho de código, montamos a equação que é utilizada pelo modelo para gerar a regressão linear utilizada para fazer as inferências necessárias, assim como tratamos os nomes e certificamos que a equação esteja de acordo com o que é esperado pela função que treinará o modelo.

Durante o treino do modelo, os dados são separados em dois conjuntos, um para o treino em si e o segundo para os testes posteriores, se estes dados já não tiverem sido separados durante a criação de outros modelos. Ao terminar de criar, a aplicação gera um arquivo *JSON* contendo os dados do modelo, como apresentado abaixo:

```

1 [
2   {
3     "model": "modelos/gam_sao_paulo.rds",
4     "response_name": "COMMON.NAME",
5     "predictors_name": "LATITUDE|LONGITUDE",
6     "data_name": "data/test_sao_paulo.csv"
7   }
8 ]

```

Onde *model* identifica onde está salvo o modelo gerado, *response_name* a(s) variável(is) de respostas, *predictors_name* os preditores usados, separados por "|", e *data_name* onde se encontram os dados a serem usados para teste.

Esse arquivo *JSON* recebe o nome do modelo junto com o nome do dataset utilizado.

3.4.1.1 Avaliação

Para avaliar o modelo, primeiro a aplicação identifica qual o tipo de dados que serão utilizados, se são categóricos ou contínuos. A partir dessa identificação, o aplicativo escolhe quais as métricas de avaliação melhor se adequam para o teste.

A parte do *script* responsável pela identificação é encontrada codificada em R no seguinte código:

```

1 response_col_name <- json_dado$response_name
2 val_response <- data_test[response_col_name]
3
4 unic_values <- length(unique(val_response))
5 all_values <- length(val_response)
6
7 percent_unic <- (unic_values * 100) / all_values
8
9 col_class <- class(val_response)

```

Com os dados armazenados nas variáveis *percent_unic* e *col_class*, o *script* em R infere com qual tipo de dados estamos trabalhando e decide qual procedimento de avaliação a ser efetuado.

```
1     if ((col_class == "factor" || col_class == "character") &&
        percent_unic < 10){
2     score_categorico(model, data_test, json_dado)
3     }else {
4     score_continuo(model, data_test, json_dado)
5     }
```

Sendo para dados contínuos, utilizadas as métricas de MAE e RMSE, e para dados categóricos, o aplicativo calcula a matriz de confusão por completo.

Ao final do processo de avaliação, o modelo retorna todos os resultados obtidos, sendo possível efetuar o teste em vários modelos simultaneamente.

Deste modo, é possível identificar qual modelo escolhido atua melhor com os dados desejados, e o modelo pode ser utilizado para processos futuros.

4 Resultados

Para identificar a viabilidade da aplicação, foi efetuado um teste utilizando dois conjuntos de dados distintos, sendo um deles utilizado para verificar a capacidade avaliativa quando tratamos de dados contínuos e o outro para avaliar quando temos dados categóricos.

Para os dados contínuos, foi utilizado o conjunto de dados *psiasci2006.csv*. Este conjunto de dados foi construído utilizando as pontuações médias em Ciências por país do Programa Internacional de Avaliação de Alunos (PISA) de 2006, juntamente com a RNB per capita (Paridade do Poder de Compra, dólares de 2005), o Índice Educacional, o Índice de Saúde e o Índice de Desenvolvimento Humano, com base em dados da ONU.

O modelo gerado a partir destes dados utilizou como parâmetros os valores de *Issue*, *Interest*, *Support*, *Income*, *Health* e *Edu*, para estimar o valor de *HDI*. Os resultados encontrados para esse caso foram:

Tabela 2 – Métricas de um modelo contínuo

Modelo	MAE	RMSE
gam_pisasci2006.json	0.0008	0.0009
glm_pisasci2006.json	0.0012	0.0015
mars_pisasci2006.json	0.0009	0.001

Fonte: Autoria do autor

O conjunto de dados *sao_paulo.csv* foi criado filtrando apenas as entradas que têm como localidade a cidade de São Paulo, encontradas em um dataset maior, o *data_2025.txt*, um dataset fornecido pelo site *eBird*, contendo avistamentos de aves em um parâmetro mundial.

Neste caso, os modelos gerados usaram como parâmetros os valores de *LATITUDE*, *LONGITUDE* e *OBSERVATION DATE* para inferir o valor de *SCIENTIFIC NAME*. Como aqui trabalhamos com dados categoricos, o sistema deveria construir a matriz de confusão dos modelos encontrados.

Mas foi encontrado um erro quando trabalhamos com dados categóricos, onde apenas o modelo GLM foi gerado corretamente, para os dois outros casos avaliados, GAM e MARS, as implementações utilizadas não conseguiram gerar modelos para serem avaliados.

Fora tentando a adaptação dos *scripts* encarregados de gerarem os modelos, para que estes fossem capazes de corrigir este erro sem afetar a generalidade do projeto, porém sem sucesso, mas este processo levantou dois pontos fundamentais, que aparentam ser a raiz do problema, o tamanho do conjunto de dados e a implementação utilizada dos modelos GAM e MARS.

Um dos erros encontrados quando fora tentando solucionar o problema, indica que o tamanho do conjunto de dados separados para treino não permitia a inferência de uma relação entre os parâmetros escolhidos para se gerar o modelo.

A segundo erro encontrado, indica que as aplicações em R utilizados para a criação dos modelos GAM e MARS, não são capazes de lidar com dados em formato de texto, a

alternativa de transformação cada texto em um valor numérico criando uma tabela auxiliar de relação foi testada, porém esta abordagem retornava ao erro mencionado anteriormente, logo uma análise mais minuciosa das aplicações em R do GAM e MARS se vê necessária, ou o teste com um conjunto de dados categóricos diferente e mais extensivo.

5 Conclusão

A criação de modelos computacionais envolve uma sequência de etapas que dependem intrinsecamente das características do conjunto de dados e dos requisitos específicos do modelo a ser treinado. Embora muitas linguagens de programação voltadas para a ciência de dados ofereçam ferramentas para automatizar partes desse processo, o desenvolvimento de um sistema verdadeiramente genérico, capaz de lidar com conjuntos de dados e modelos arbitrários, apresenta desafios significativos. A principal complexidade reside na necessidade de adaptar dinamicamente o método de avaliação ao tipo de dado em análise.

O sistema desenvolvido neste trabalho demonstrou ser eficaz na criação e avaliação de modelos de regressão para dados contínuos. Onde este foi capaz de gerar corretamente os modelos GAM, GLM e MARS, assim como seus respectivos testes, e inferir apartir dos dados qual comainho de treino e avaliação seguir.

Para dados categóricos, o modelo GLM foi implementado com sucesso, indicando que os mecanismos de identificação de variável resposta e seleção de métricas funcionam para este caso. No entanto, ao lidar com dados categóricos, os scripts responsáveis pela geração dos modelos GAM e MARS não conseguiram interpretar corretamente as especificações para o treinamento, o que comprometeu a generalização do processo e impediu a avaliação comparativa completa.

A construção de um sistema generalista para a criação e avaliação de modelos com conjuntos de dados arbitrários revelou-se, portanto, mais complexa do que o previsto inicialmente. A dificuldade em generalizar os scripts de treinamento e teste para diferentes tipos de dados e modelos constitui o principal obstáculo para a concepção de tal sistema. Isso sugere a necessidade de abordagens mais sofisticadas, como a criação de scripts especializados para cada combinação de modelo e tipo de dado, ou o desenvolvimento de uma nova abstração para gerenciar as informações necessárias ao treinamento.

Conclui-se que, embora a criação de um sistema generalista para a construção e avaliação de modelos seja um objetivo alcançável, a sua implementação requer uma atenção especial à generalização dos scripts de treinamento e teste. Os problemas enfrentados na criação dos modelos GAM e MARS com dados categóricos evidenciam a necessidade de uma análise mais aprofundada das particularidades de cada modelo e da forma como eles interagem com diferentes tipos de dados.

5.1 Trabalhos Futuros

Para aprimorar o sistema desenvolvido, propõem-se os seguintes trabalhos futuros:

1. **Melhoria da Robustez para Diversos Tipos de Dados:** Aumentar a capacidade do sistema para lidar com uma gama mais ampla de tipos de dados, garantindo a correta interpretação e processamento, especialmente para variáveis categóricas complexas.
2. **Visualização Gráfica das Predições:** Implementar funcionalidades para a visualização gráfica das predições dos modelos gerados, permitindo uma análise mais

intuitiva e compreensível dos resultados.

3. **Facilitação da Configuração de Banco de Dados Externos:** Desenvolver ferramentas que simplifiquem a configuração e a integração com bancos de dados externos, tornando o sistema mais versátil e adaptável a diferentes infraestruturas de dados.
4. **Capacidade de Efetuar Predições no Próprio Sistema:** Adicionar a funcionalidade de realizar predições diretamente no sistema, utilizando os modelos treinados, o que permitiria uma validação e aplicação mais ágil dos resultados.

Referências

- ADALARDO. 7. *Modelos Lineares*. 2020. Acesso em: 26 de Abril de 2025. Disponível em: <http://ecor.ib.usp.br/doku.php?id=03_apostila:06-modelos#:~:text=SÃo%20chamados%20modelos%20lineares%20aqueles,dos%20demais%20parÃmetros%20do%20modelo.> Citado na página 14.
- AMETEPEY, S. O.; ANSAH, S. K. Impacts of construction activities on the environment : the case of ghana. *Journal of Construction Project Management and Innovation*, v. 4, n. sup-1, p. 934–948, 2014. Disponível em: <<https://journals.co.za/doi/abs/10.10520/EJC162729>>. Citado na página 10.
- AUGUSTO, D. A. *Entenda o que são modelos computacionais e como o SISS-Geo os utiliza*. 2025. Acesso em: 25 de Abril de 2025. Disponível em: <<https://www.biodiversidade.ciiss.fiocruz.br/entenda-o-que-sao-modelos-computacionais-e-como-o-siss-geo-os-utiliza>>. Citado na página 13.
- AWARI. *Conheça as principais linguagens de programação para Ciência de Dados*. 2022. Acesso em: 25 de Abril de 2025. Disponível em: <<https://awari.com.br/linguagens-de-programacao-para-ciencia-de-dados/>>. Citado 2 vezes nas páginas 10 e 24.
- CHEIN, F. *Introdução aos Modelos de Regressão Linear*. Enap, 2019. ISBN 9788525601155. Disponível em: <https://repositorio.enap.gov.br/bitstream/1/4788/1/Livro_RegressÃo%20Linear.pdf>. Citado 3 vezes nas páginas 14, 15 e 16.
- CLARK, M. *Generalized Additive Models*. [S.l.], 2025. Acesso em: 25 de Maio de 2025. Disponível em: <<https://m-clark.github.io/generalized-additive-models/application.html#single-feature>>. Citado na página 25.
- CORMEN, T. et al. *Introduction to Algorithms, third edition*. MIT Press, 2009. (Computer science). ISBN 9780262033848. Disponível em: <<https://books.google.com.br/books?id=i-bUBQAAQBAJ>>. Citado na página 11.
- COSME, A. L. *Modelagem computacional: o que é, qual sua aplicação*. 2025. Acesso em: 17 de Abril de 2025. Disponível em: <<https://123ecos.com.br/docs/modelagem-computacional/>>. Citado na página 10.
- COSME, A. L. *Modelagem computacional: o que é, qual sua aplicação*. 2025. Acesso em: 25 de Abril de 2025. Disponível em: <<https://123ecos.com.br/docs/modelagem-computacional/#:~:text=Os%20principais%20tipos%20sÃo%20a,em%20diferentes%20Ãreas%20do%20conhecimento.>> Citado na página 13.
- DEVELOPERS, G. for. *Classificação: precisão, recall, precisão e métricas relacionadas*. 2024. Acesso em: 3 de Maio de 2025. Disponível em: <<https://developers.google.com/machine-learning/crash-course/classification/accuracy-precision-recall?hl=pt-br>>. Citado na página 19.
- DUARTE, R. *Métricas de Avaliação em Modelos de Classificação em Machine Learning*. 2024. Acesso em: 17 de Maio de 2025. Disponível em: <<https://sigmoidal.ai/>>

[metricas-de-avaliacao-em-modelos-de-classificacao-em-machine-learning/>](#). Citado na página 18.

EBAC. *Regressão Linear: teoria e exemplos*. 2023. Acesso em: 27/04/2025. Disponível em: <https://ebaonline.com.br/blog/regressao-linear-seo>. Citado na página 15.

ELITH, J.; LEATHWICK, J. R. Species distribution models: Ecological explanation and prediction across space and time. *Annual Review of Ecology, Evolution, and Systematics*, Annual Reviews, v. 40, n. Volume 40, 2009, p. 677–697, 2009. ISSN 1545-2069. Disponível em: <https://www.annualreviews.org/content/journals/10.1146/annurev.ecolsys.110308.120159>. Citado 2 vezes nas páginas 10 e 19.

FILHO, M. *O Que É Acurácia Em Machine Learning?* 2023. Acesso em: 3 de Maio de 2025. Disponível em: <https://mariofilho.com/o-que-e-acuracia-em-machine-learning/>. Citado 2 vezes nas páginas 18 e 19.

FRIEDMAN, J. H. Multivariate Adaptive Regression Splines. *The Annals of Statistics*, Institute of Mathematical Statistics, v. 19, n. 1, p. 1 – 67, 1991. Disponível em: <https://doi.org/10.1214/aos/1176347963>. Citado 3 vezes nas páginas 10, 22 e 26.

FRIEDMAN, J. H.; ROOSEN, C. B. An introduction to multivariate adaptive regression splines. *Statistical Methods in Medical Research*, v. 4, n. 3, p. 197–217, 1995. PMID: 8548103. Disponível em: <https://doi.org/10.1177/096228029500400303>. Citado 3 vezes nas páginas 22, 23 e 24.

GUISAN, A.; EDWARDS, T. C.; HASTIE, T. Generalized linear and generalized additive models in studies of species distributions: setting the scene. *Ecological Modelling*, v. 157, n. 2, p. 89–100, 2002. ISSN 0304-3800. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0304380002002041>. Citado 4 vezes nas páginas 10, 20, 21 e 26.

HASTIE, T.; TIBSHIRANI, R. Generalized Additive Models. *Statistical Science*, Institute of Mathematical Statistics, v. 1, n. 3, p. 297 – 310, 1986. Disponível em: <https://doi.org/10.1214/ss/1177013604>. Citado 4 vezes nas páginas 10, 21, 22 e 26.

HASTIE, T. et al. *Package 'mda'*. 0.5-5. ed. [S.l.], 2024. <https://CRAN.R-project.org/package=mda>. Disponível em: <https://cran.r-project.org/web/packages/mda/mda.pdf>. Citado 2 vezes nas páginas 20 e 25.

HYNDMAN, R. J.; KOEHLER, A. B. Another look at measures of forecast accuracy. *International Journal of Forecasting*, v. 22, n. 4, p. 679–688, 2006. ISSN 0169-2070. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0169207006000239>. Citado na página 18.

IBM. *Modelos lineares*. 2025. Acesso em: 26 de Abril de 2025. Disponível em: <https://www.ibm.com/docs/pt-br/spss-modeler/18.5.0?topic=node-linear-models>. Citado na página 14.


NORBERG, A. et al. A comprehensive evaluation of predictive performance of 33 species distribution models at species and community levels. *Ecological Monographs*, v. 89, n. 3, p. e01370, 2019. Disponível em: <https://esajournals.onlinelibrary.wiley.com/doi/abs/10.1002/ecm.1370>. Citado 4 vezes nas páginas 11, 20, 25 e 26.

- NOVAK, H. *Modelos de Regressão Linear e como aplicamos a técnica na Loft*. 2022. Acesso em: 27/04/2025. Disponível em: <<https://medium.com/loftbr/regressão-linear-65fc8caeb729>>. Citado na página 17.
- OLIVER, J. *A very brief introduction to species distribution models in R*. 2024. Acesso em: 4 de Maio de 2025. Disponível em: <[https://jcoliver.github.io/learn-r/011-species-distribution-models.html#:~:text=\(\"predicts\"\),Components%20of%20the%20model,these%20data%20\(see%20below\).>](https://jcoliver.github.io/learn-r/011-species-distribution-models.html#:~:text=(\)> Citado na página 19.
- PAUL, S.; SAHA, K. K. The generalized linear model and extensions: a review and some biological and environmental applications. *Environmetrics*, v. 18, n. 4, p. 421–443, 2007. Disponível em: <<https://onlinelibrary.wiley.com/doi/abs/10.1002/env.849>>. Citado 3 vezes nas páginas 10, 20 e 26.
- RICHTER, F. *Amazon and Microsoft Stay Ahead in Global Cloud Market*. 2025. Acesso em: 19 de Abril de 2025. Disponível em: <<https://www.statista.com/chart/18819/worldwide-market-share-of-leading-cloud-infrastructure-service-providers/>>. Citado na página 10.
- RSTUDIO Desktop. 2025. Acesso em: 10 de Maio de 2025. Disponível em: <<https://posit.co/download/rstudio-desktop/>>. Citado na página 24.
- SPICKER, D. *Quasi-Likelihood Theory in Full*. 2025. Acesso em: 23 de Maio de 2025. Disponível em: <https://dylanspicker.com/courses/STAT437/course_index.html>. Citado na página 21.
- STOCKMAN, A. K.; BEAMER, D. A.; BOND, J. E. An evaluation of a garp model as an approach to predicting the spatial distribution of non-vagile invertebrate species. *Diversity and Distributions*, v. 12, n. 1, p. 81–89, 2006. Disponível em: <<https://onlinelibrary.wiley.com/doi/abs/10.1111/j.1366-9516.2006.00225.x>>. Citado na página 11.
- THE R Project for Statistical Computing. 2025. Acesso em: 10 de Maio de 2025. Disponível em: <<https://www.r-project.org>>. Citado na página 24.
- WILLMOTT, C. J.; MATSUURA, K. Advantages of the mean absolute error (mae) over the root mean square error (rmse) in assessing average model performance. *Climate Research*, Inter-Research Science Center, v. 30, n. 1, p. 79–82, 2005. ISSN 0936577X, 16161572. Disponível em: <<http://www.jstor.org/stable/24869236>>. Citado na página 17.
- WISZ, M. S. et al. Effects of sample size on the performance of species distribution models. *Diversity and Distributions*, v. 14, n. 5, p. 763–773, 2008. Disponível em: <<https://onlinelibrary.wiley.com/doi/abs/10.1111/j.1472-4642.2008.00482.x>>. Citado na página 11.
- WOOD, S. *Package 'mgcv'*. 1.9-3. ed. [S.l.], 2025. <https://CRAN.R-project.org/package=mgcv>. Disponível em: <<https://cran.r-project.org/web/packages/mgcv/mgcv.pdf>>. Citado 2 vezes nas páginas 20 e 25.
- ZHANG, W.; GOH, A. Multivariate adaptive regression splines for analysis of geotechnical engineering systems. *Computers and Geotechnics*, v. 48, p. 82–95, 2013.

ISSN 0266-352X. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0266352X1200198X>>. Citado na página 23.

Apêndices

APÊNDICE A – Arquitetura do sistema



Fonte: Elaboração do autor